

Analyse multivariee des profils d'etudiants

Dataset : Predict Students' Dropout and Academic Success

Problematique

Comment identifier des profils d'etudiants a partir de variables administratives, socio-economiques et academiques, et comment ces profils se differentient-ils selon

Dropout , Enrolled OU Graduate ?

Equipe

Nour BEN HASSINE, Nouha BEN KHELIL, Hadir FELLI, Nouha BRIKI

Figure recommandee : `outputs/figures/03_a_distribution_target.png`

Message oral : "Notre objectif est de construire une typologie interpretable, pas seulement de predire un statut."

Justification statistique : analyse exploratoire multivariee sur donnees mixtes.

2. Contexte et objectif du projet

- Dataset UCI sur la réussite et le décrochage dans l'enseignement supérieur.
- Données mixtes : variables quantitatives, qualitatives et binaires.
- Objectif principal : comprendre la structure des profils étudiants.
- Méthodes : analyse descriptive, FAMD, clustering, régression logistique complémentaire.

Pipeline

Dataset -> Préparation -> FAMD principale réduite -> Clustering k-means -> Régression logistique -> Recommandations

Message oral : "Nous avons séparé l'analyse exploratoire non supervisée de la modélisation complémentaire supervisée."

Justification statistique : la FAMD traite les variables mixtes avant le clustering.

3. Dataset et variable Target

- 4 424 étudiants.
- Variable cible `target` a 3 modalités : `Dropout` , `Enrolled` , `Graduate` .
- `target` sert a caracteriser les profils apres calcul.
- Elle n'est jamais active dans la FAMD ni dans le clustering.

Distribution

Target	Effectif	Pourcentage
Dropout	1 421	32,12 %
Enrolled	794	17,95 %
Graduate	2 209	49,93 %

Figure recommandee : `outputs/figures/03_a_distribution_target.png`

4. Preparation et typologie des variables

- Les variables qualitatives codees par des entiers sont converties en facteurs.
- Les variables creees `dropout_binary` et `success_binary` sont exclues des analyses non supervisees.
- Les zeros academiques sont verifies et conserves comme informations possibles.
- Les valeurs atypiques ne sont pas supprimees automatiquement.

Tables recommandees

- `outputs/tables/04_principale_variables_actives.csv`
- `outputs/tables/04_principale_variables_supplementaires.csv`
- `outputs/tables/08_typologie_variables.csv`
- `outputs/tables/08_audit_famd_principale_reduite.csv`

Message oral : "Le type informatique ne suffit pas : une variable integer peut etre une

5. Pourquoi la FAMD ?

- ACP seule : adaptee surtout aux variables quantitatives.
- ACM seule : adaptee surtout aux variables qualitatives.
- FAMD : combine les deux dans un meme espace factoriel.
- FAMD principale reduite : 11 variables actives defendables.
- `target` reste illustrative uniquement.

Variables actives

- Quantitatives : notes, age, evaluations, unites validees du semestre 1.
- Qualitatives : regime jour/soir, debiteur, frais a jour, genre, boursier.

Message oral : "La FAMD est coherente avec la nature mixte du dataset et avec le cours."

6. Resultats FAMD principale reduite

- Dim.1 : principalement liee au niveau academique.
- Dim.2 : lecture complementaire du parcours et du contexte socio-administratif.
- Inertie Dim.1 : 21,81 %.
- Inertie Dim.2 : 15,95 %.
- Inertie cumulee Dim.1 + Dim.2 : 37,76 %.

Figures recommandees

- `outputs/figures/04_principale_screepplot.png`
- `outputs/figures/04_principale_variables_top.png`
- `outputs/figures/04_principale_individus_target.png`
- `outputs/figures/04_principale_barycentres_target.png`

7. Pourquoi clustering sur coordonnees FAMD ?

- Les donnees brutes melangent echelles numeriques et categories.
- Les coordonnees FAMD donnent un espace numerique homogene.
- Le clustering est donc applique aux individus projetes dans cet espace.
- `target` n'intervient pas dans la construction des clusters.

Figure recommandee : `outputs/figures/05_principale_clusters_famd.png`

Message oral : "On ne regroupe pas directement les lignes brutes ; on regroupe les individus dans l'espace FAMD."

Justification statistique : distance plus coherente pour des donnees mixtes.

8. Validation du clustering principal

- Solution principale : `nb_axes = 2` , `k = 2` .
- Silhouette moyenne : 0,508.
- Taille minimale : 929 etudiants.
- Taille maximale : 3 495 etudiants.
- Stabilité : ARI moyen = 1,00 sur 30 repetitions.

Figures recommandees

- `outputs/figures/05_principale_methode_coude.png`
- `outputs/figures/05_principale_silhouette_moyenne.png`
- `outputs/figures/05_principale_dendrogramme_cah.png`

Message oral : "k = 2 est retenu apres recalcul sur la FAMD principale reduite ; c'est une solution stable et lisible "

9. Profils obtenus : Cluster 1 vs Cluster 2

Profil	Effectif	Dropout	Graduate	Lecture
Cluster 1	929	81,5 %	8,9 %	Profil a risque eleve
Cluster 2	3 495	19,0 %	60,8 %	Profil majoritaire favorable

- Cluster 1 : indicateurs academiques faibles, profil prioritaire a surveiller.
- Cluster 2 : indicateurs academiques meilleurs, profil plus favorable.
- `target` est utilisee apres clustering pour caracteriser les groupes.

Figures recommandees

- `outputs/figures/05_principale_composition_clusters_target.png`
- `outputs/figures/05_principale_profils_academiques_clusters.png`

Message oral : "La typologie finale oppose un groupe a risque eleve et un groupe

10. Regression logistique complementaire

- Cible binaire : Dropout vs Non_Dropout .
- Modele precocce : variables d'entree + semestre 1.
- Modele complet : variables d'entree + semestre 1 + semestre 2.
- Le modele complet est plus performant mais disponible plus tard.

Modele	Accuracy	Recall Dropout	F1 Dropout	AUC
Precocce	0,849	0,716	0,753	0,884
Complet	0,865	0,747	0,780	0,909

Figures recommandees

- outputs/figures/06_roc_logit_precocce.png
- outputs/figures/06_roc_logit_complet.png

11. Recommandations operationnelles

- Mettre en place un suivi academique precoce apres le premier semestre.
- Prioriser les etudiants du cluster 1.
- Surveiller les signaux administratifs et financiers : debiteur, frais a jour.
- Utiliser le modele precoce comme logique d'alerte possible.
- Lire les resultats avec prudence avant toute generalisation.

Figure recommandee :

`outputs/figures/05_principale_profils_academiques_clusters.png`

Message oral : "Les recommandations sont des pistes d'aide a la decision, pas des decisions automatiques."

Justification statistique : combinaison entre typologie exploratoire et modele complementaire.

12. Limites methodologiques

- Analyse exploratoire, non supervisee pour la FAMD et le clustering.
- Projection 2D partielle : Dim.1 + Dim.2 = 37,76 % d'inertie.
- $k = 2$ est robuste et lisible, mais moins detaille qu'une typologie plus fine.
- Les donnees viennent d'une cohorte specifique.
- Une validation externe sur d'autres cohortes serait necessaire.

Message oral : "Nous assumons une lecture prudente : le projet met en evidence des structures et des associations."

Justification statistique : absence de validation externe et nature exploratoire du clustering.

13. Conclusion

- Le projet combine analyse descriptive, FAMD, clustering et regression logistique.
- La FAMD principale reduite fournit un espace adapte aux donnees mixtes.
- Le clustering principal identifie deux profils interpretable.
- La regression logistique confirme l'interet informatif des variables academiques.
- Les resultats soutiennent une logique d'alerte et d'accompagnement.

Message oral : "La contribution principale est une typologie defendable, claire et utile pour comprendre les parcours etudiants."

Phrase finale :

"Notre analyse suggere que les performances academiques precoces structurent fortement les profils, et que le cluster 1 merite une attention prioritaire."

14. Questions possibles de soutenance

- Pourquoi FAMD et pas ACP ?
- Pourquoi `target` illustrative ?
- Pourquoi semestre 2 supplémentaire ?
- Pourquoi clustering sur coordonnees FAMD ?
- Pourquoi `k = 2` ?
- Que signifie silhouette = 0,508 ?
- Les resultats sont-ils causaux ?
- Difference entre modele precoce et modele complet ?

Table recommandee : `outputs/tables/08_questions_soutenance_reponses.csv`

Message oral : "Nous pouvons defendre chaque choix par la coherence entre type de donnees, methode et objectif exploratoire."